重機旅遊規劃顧問（Moto Touring Copilot）

結合個人配速模型與外部驗證的多 Agent 重機旅遊規劃系統

物聯網應用與資料分析（AIoT-DA）期末專題提案 ｜ 第 12 組

2026 年 11 月

目錄

Abstract 摘要 4

1. Introduction 緒論 5

1.1 A. Attention Getter：一個沒有跟上目標的數字 5

1.2 B. Background：台灣的重機旅遊 5

1.3 C. Problem：要回答的問題 6

1.4 D. Existing Limitations：現有方法的不足 6

1.5 E. Innovation：本專題的不同之處 7

1.6 F. Contributions：預期貢獻 7

2. Related Work 相關研究 9

2.1 分類架構 9

2.2 AI 技術 9

2.3 領域知識 11

2.4 方法比較 12

2.5 Article Summary Table 14

2.6 既有產品 15

2.7 Existing Research → Limitations → Research Gap → Our Project 16

3. Deep Research 深度研究 18

3.1 Q1. 五個核心思維模式 18

3.2 Q2. 三個最重要的專業爭論 20

3.3 Q3. 十個深度理解問題 21

4. Proposed Scheme 系統設計 24

4.1 研究目標（PA） 24

4.2 理論與技術基礎（PB）..... 24
4.3 問題成因與解法（PC：Cause → Mechanism → Solution）..... 24
4.4 系統架構（PD、PG）..... 25
4.5 核心元素與符號（PE）..... 28
4.6 數學模型（PF）..... 28
4.7 處理流程（PI：Flowchart）..... 31
4.8 核心演算法（Pseudocode）..... 31
4.9 範例（PJ）..... 32
4.10 資料與工具..... 33
4.11 評估計畫（PL）..... 34
4.12 主要創新（PK）..... 35
4.13 可行性與限制..... 35
參考文獻 References..... 37
附錄 A：AI 使用說明..... 43

Abstract 摘要

台灣 2025 年道路交通事故死亡 2,858 人，機車使用者占 60.9% [1]；大型重型機車至 2025 年底登記 279,703 輛 [2]。重機騎士出發前想知道的是「照我的騎法，幾點出發才能在天黑前回家、哪裡加油、哪一段有風險」，但一般導航只給群體平均的預估時間 [3]，重機 App 著重路線 [4]，大型語言模型（LLM）單獨規劃在 TravelPlanner 的最終通過率僅 0.6% [5]。

本專題提出「重機旅遊規劃顧問（Moto Touring Copilot）」：以騎士自己的 279 趟 GPX 行程訓練個人配速模型，輸出 P50 / P90 時間；五個 Agent 依各路段的預計抵達時間整合中央氣象署、交通部 TDX 與加油站資料，由驗證規則檢查日照、續航、天氣與封路，不通過即重新規劃。

評估將比較個人配速模型與 Google Maps 兩輪車預估時間等基準，並以獨立於 Agent 的 oracle 進行消融實驗；以上成效均為待驗證的假設，本提案不含實驗結果。

關鍵詞： 多 Agent 系統、行程規劃、旅行時間預測、分位數迴歸、重型機車、資料分析

1. Introduction 緒論

1.1 A. Attention Getter：一個沒有跟上目標的數字

依交通部道安資訊查詢網的初估值，台灣 2025 年道路交通事故 30 日死亡 2,858 人，比 2024 年只少 92 人，降幅 3.1% [1]；政府為 2030 年死亡人數減半，訂下每年減少 7% 的目標，2025 年只達成約四成 [6]。其中機車騎士 1,740 人，占 60.9%；2023、2024 年也都在六成以上 [1]。交通部檢討時指出，機車與高齡者死亡偏多，事故型態中自摔、自撞的比例較為嚴重 [7]。

騎重機旅遊的人也愈來愈多。大型重型機車登記數在 2025 年底為 279,703 輛，五年內增加 56.4%，十年內約成長為 3.1 倍 [2]；不過新車領牌數從 2023 年的 27,200 輛降到 2025 年的 15,506 輛 [2]，表示總量仍在成長，但增速正在放緩。本專題不宣稱能降低事故率，而是從出發前的規劃切入：騎乘時間估錯、天黑前趕路、遇到午後雷雨或封路，都是規劃階段就能先看見的風險。

1.2 B. Background：台灣的重機旅遊

重機旅遊常是一天來回或兩天一夜的山區路線，例如台 20 線南橫、台 8 線中橫、台 14 甲線。這類路線有三個特性。第一，天氣隨時間變化：台灣暖季在綜觀天氣弱時，午後雷雨在 15 至 16 時最強，降雨頻率最高的地方是沿山坡下段的狹長帶 [8]，騎士在山上的時段直接決定會不會遇雨。第二，道路可能預防性封閉：2025 年 7 月 19 日與 9 月 22 日，公路局都因颱風豪雨對南橫部分路段實施預警性封閉 [9][10]。第三，補給點少，山區加油站間距長、營業時間有限。

相關資料已經公開：氣象署提供鄉鎮逐 3 小時預報、逐時觀測、日出日沒時刻與警特報 [11]，交通部 TDX 提供每分鐘更新的省道路況 [12]。騎士自己也常有車載 App 記錄的 GPX 軌跡，每一段路的實際騎乘時間都在裡面。技術上，LLM Agent 已能理解自然語言並呼叫外部工具，讓「用對話規劃行程」變得可行。

1.3 C. Problem：要回答的問題

使用者的問題通常是：「週六想騎南橫來回，幾點出發才能在天黑前回到家？中途哪裡加油？哪一段可能下雨或封路？」把它拆開，系統要同時處理三件事：

1. **個人化的時間預測：** 依這位騎士過去的騎法，預測每一段路要騎多久，並給出範圍，而不是單一數字。
2. **時間對齊的風險查詢：** 依「預計抵達該路段的時間」去查那個時段的鄉鎮預報、日落時間和路況，而不是只看出發地的天氣。
3. **跨條件的一致性檢查：** 各段時間加總、回程是否在日落前、加油距離是否超過續航，彼此要互相吻合。

本專題要解決的問題定義為：給定起訖點、途經路線、日期與騎士的歷史 GPX，產生一份可驗證的行程計畫，包括建議出發時間（附範圍）、加油點與各路段的風險說明，並附上每個數字的資料出處。

1.4 D. Existing Limitations：現有方法的不足

一般導航的預估時間不是個人化的。 Google 地圖 2018 年在台灣推出機車模式，官方說明是以機器學習把機車行駛速度納入考量 [13]；Google Maps 的 ETA 模型則以整體車流資料訓練，目標是讓多數用路人的預估更準 [3]。官方說明沒有提到依個別騎士的紀錄調整，也沒有提供時間範圍，而山區彎道路段的騎乘時間因人差異很大。

重機 App 著重路線與紀錄，不處理時間與風險的整合。 Calimoto、Kurviger、REVER 提供彎道路線規劃、環線、騎乘紀錄與位置分享，REVER 付費方案有天氣警示 [4][14]；評測與官方功能清單都沒有提到個人化的抵達時間預測或封路提示。

單靠 LLM 做不好時間與空間的計算。 在 TravelPlanner 基準中，GPT-4-Turbo 自己用工具蒐集資料再規劃，同時滿足所有硬性與常識限制的最終通過率只有 0.6% [5]；更貼近真實旅遊情境的 RETAIL 基準中，最強的既有模型通過率也只有 1.0% [15]；MapEval 測試 30 個基礎模型，沒有一個在地圖推理上超過 67%，距離與路線規劃是主要弱項 [16]。加上外部驗證後結果明顯改善：LLM-Modulo 用 critics 檢查計畫，把 GPT-4-Turbo 的通過率從 4.4% 提升到 20.6% [17]；把問題交給 SMT 求解器的方法達到

93.9% [18]。這些研究處理的是機票、住宿型的行程，沒有涵蓋騎乘配速、逐時天氣與日落時間這類連續時間的限制。

資料分散。 預報、日落、路況與加油站分屬不同平台，目前要靠騎士自己逐一查詢、自己換算時間。

1.5 E. Innovation：本專題的不同之處

1. **用自己的 GPX 學配速，並輸出範圍。** 以騎士歷史行程的實際騎乘時間為正確答案，依曲率、坡度、道路等級等特徵預測每段時間，給出 P50 與 P90，再和 Google Maps 二輪車路線的預估時間比較 [19]。
2. **依預計抵達時間查風險。** 先算出每段的預計抵達時段，再用該時段的鄉鎮預報、日落時間與路況評估風險，讓午後雷雨這類隨時間變化的因素能落到具體路段上。
3. **把驗證放進規劃迴圈。** 參考 LLM-Modulo 的作法 [17]，由驗證 Agent 用明確規則檢查計畫，不通過就退回重新規劃，LLM 只負責理解需求、分派工作與解釋結果，數字一律來自工具計算。
4. **回答附出處。** 用知識庫保存氣象署警特報說明、公路局行車資訊與騎乘安全資料，回答時附上來源。

本專題的定位是個人化的出發前決策輔助，不做事故預測。

1.6 F. Contributions：預期貢獻

以下為預期貢獻，實際成效待期末實驗驗證。

1. **個人配速模型與預測區間。** 從 279 趟 GPX 建立路段資料表，以多元迴歸與梯度提升樹（分位數損失）預測路段與整趟時間，輸出 P50／P90。Baseline 為平均速度、速限換算與 Google Maps 二輪車預估時間 [19]；指標為 MAE、MAPE 與 P90 區間覆蓋率，採依行程分組的交叉驗證，並以最新行程做時間外推測試。預期可量化個人模型在山區路段與導航預估時間的差距。
2. **具驗證與重新規劃的多 Agent 規劃器。** 規劃、配速分析、天氣、路況與補給、驗證五個 Agent 分工；驗證規則包括回程是否早於日落、各段時間加總是否一致、加油距離是否在續航內、回答中的數字是否都能追溯到工具輸出，不通過則重新規劃並設次數上限。預期產出可檢查、可追溯的行程計畫。
3. **台灣開放資料與知識庫的整合。** 串接氣象署鄉鎮預報、觀測、日出日沒與警特報 [11]、TDX 省道路況 [12]、內政部地形、加油站資料與 OpenStreetMap 路網，

並建立附出處的領域知識庫。預期提供一套可重複使用的資料取得與前處理流程。

4. **含消融實驗的評估設計。** 準備 20 至 30 題規劃問題，比較「只用 LLM」「LLM + 知識庫」「完整 Agent（工具 + 驗證迴圈）」三種做法對獨立 oracle（事先算好的暮光終、營業時間、管制事件與實際行程時間）的違規率、時間誤差與一致率，並報告拒答率；另以歷史行程回測，並做 2 至 3 個完整案例。預期能說明工具計算與驗證迴圈各自帶來多少改善。

本專題只有一位騎士的資料（n = 1），結論限於個人化情境；方法上任何匯入自己 GPX 的騎士都能各自訓練。騎乘中即時回傳與語音提醒列為 L3 延伸，不在 Proposal 承諾範圍內。

---

2. Related Work 相關研究

2.1 分類架構

本專題同時涉及「預測一段路要騎多久」與「讓 LLM 排出可行的行程」兩件事，再加上重機騎乘與台灣山區環境的領域知識。相關研究依下列分類整理：

類別	子題	文獻
A. AI 技術	A1 旅行時間預估（Travel Time Estimation, TTE）	[20] [3] [21]
	A2 LLM Agent 行程規劃與驗證	[5] [18] [16] [17] [22]
B. 領域知識	B1 機車在彎道的速度行為	[23] [24]
	B2 以地形預測移動速度（個人配速的類比）	[25]
	B3 騎乘風險：彎道、天氣、封路	[26] [8] [27]
C. 既有產品	重機導航與路線規劃 App	[13][28]–[31]

2.2 AI 技術

A1 旅行時間預估：由加總路段到端對端，再到機率分布

加總路段時間。 最直觀的做法是把路徑切成路段，分別估時間後相加；本專題的平均速度與速限換算 baseline 屬於這一類。DeepTTE [20] 指出這種做法忽略路口與號誌，局部誤差會累積。

端對端深度學習（2018）。 DeepTTE [20] 直接預測整條路徑的時間：以 geo-convolution 把地理資訊放進卷積，疊上 recurrent 單元捕捉時間相依，並以 multi-task learning 同時預測整段與各局部子路徑的時間。作者在兩個大規模軌跡資料集上報告優於當時方法；作者程式庫附的範例資料來自成都，並註明要接近論文結果需要五百萬條以上軌跡。

圖神經網路與產品部署（2021）。 Google Maps 的 GNN ETA [3] 把常見路線上相連的路段組成 supersegment（路段平均約 50–100 m，一個 supersegment 約 20 段），輸入即時速度、過去 17 週的歷史速度、路段長度與道路等級，已在 Google Maps 上線，摘要

報告在 Sydney 等城市把負面 ETA 結果降低 40% 以上。論文也承認只涵蓋約一百萬個預先定義的 supersegment，較冷門的地面道路改用較簡單的逐段模型。

機率式預估（2024 – 2025）。 ProbETA [21] 認為天氣與駕駛行為會讓不同行程的時間彼此相關，因此以 low-rank 多變量高斯分布同時建模行程之間與行程內部的相關，在成都與哈爾濱兩個網約車資料集上 MAPE 比既有方法降低 12.60% 以上，並以 CRPS 評估分布品質。它的限制是假設旅行時間服從高斯分布，且訓練資料只有各 6 天。

這一條演進線的共同點： 資料都是城市汽車或計程車軌跡、目標是群體平均，模型需要大量軌跡；三篇在我們讀到的範圍內都沒有處理機車、山區彎道或單一使用者的個人化。

A2 LLM Agent 行程規劃：由「直接生成」到「外部驗證」

LLM 直接規劃的能力不足（2024 – 2025）。 TravelPlanner [5] 提供 1,225 個旅遊需求、六種搜尋工具與近四百萬筆資料，要求 Agent 同時滿足常識限制與使用者的硬限制（預算、房型等）。GPT-4-Turbo 以 ReAct 自己用工具蒐集資料再規劃時，final pass rate 只有 0.6%；直接提供資料、只做規劃時也只有 4.4%。主要失敗原因包括工具參數錯誤、重複無效動作、幻覺，以及無法同時追蹤多個全域限制。MapEval [16] 以 180 個城市、54 個國家的 700 題地理問題測試 30 個 foundation model，沒有一個超過 67%，且都落後人類 20% 以上；摘要指出模型在距離、方向、路線規劃上特別弱。

加入外部批評器（2024）。 LLM-Modulo [17] 讓 LLM 負責產生與改寫計畫，再由一組 critic 檢查並回饋。在 TravelPlanner 上，GPT-3.5-Turbo 由 0% 提升到 5%，GPT-4-Turbo 約為原本的 4.6 倍。

交給形式化求解器（2025）。 Hao 等人 [18] 把多限制規劃問題轉成 constraint satisfiability 問題，交給 SMT 類求解器求解，在 TravelPlanner 上成功率 93.9%（摘要提到 o1-preview 在資訊齊全時約 10%）。無解時，系統取出 unsatisfiable core 說明失敗原因並建議修改。

檢索增強與時空約束（2025）。 TP-RAG [22] 建立 2,348 個真實旅遊需求、85,575 個標註 POI 與 18,784 條參考行程的 benchmark，發現加入參考行程能改善路線效率，但參

考資料互相衝突或有雜訊時會降低穩健性；作者提出的 EvoRAG 結合檢索行程與 LLM 推理，減少常識違規。

多 Agent 與即時環境（2025–2026）。 RETAIL [15] 把旅遊規劃推向真實情境，最強的既有模型通過率只有 1.0%，作者以主題導向的多 Agent 框架 TGMA 提升到 2.72%，並加入環境感知以確保計畫可行。Vaiage [32] 以多個 Agent 搭配外部 API 與地圖回饋做個人化行程，完整系統平均 8.5 分（滿分 10），拿掉策略或外部 API 分別降到 7.2 與 6.8 分（作者自評，僅讀到摘要）。ROAM [33] 以時空檢索層把天氣預報、實際道路距離與 POI 營業時間放進提示，再以 ReAct 式 Agent 處理使用者的修改要求並重新檢查可行性；它的重新規劃針對使用者編輯，沒有處理封路。三者都把外部環境帶進規劃，但都以城市景點行程為對象，也都沒有依個人速度推算各點的抵達時間。

這一條演進線的共同點： 結論一致指向「LLM 負責理解與組織，數字與限制交給外部工具計算和驗證」。但這些 benchmark 的限制多是預算、POI、交通班次與城市間移動，都沒有「每段路要騎多久」「天黑前回得來嗎」「油夠不夠到下一個加油站」這類依賴個人配速與即時環境的限制。

2.3 領域知識

B1 機車在彎道的速度行為

道路設計領域長期用 operating speed model（以道路幾何預測自由車流第 85 百分位速度）描述彎道車速。Lemonakis 等人 [23] 指出既有模型多以小客車、貨車為對象，很少考慮機車，但機車騎士在事故中比例偏高，尤其是平曲線；他們以裝有儀器的機車，由有經驗的騎士在自然騎乘條件與不同照明下，於希臘雙車道鄉道量測，篩選影響運行速度的幾何參數，建立簡化的機車速度模型。

Geedipally 等人 [24] 用 SHRP 2 車速資料檢驗彎道速度模型能否跨州移轉：Texas 的速度差模型乘上一個調整係數後可以用在 Indiana；熟悉路線的駕駛在彎道中點的第 85 百分位速度高於不熟悉的駕駛，而模型對不熟悉路線者的預測較準。這說明「同一條彎道，不同人、不同熟悉度會騎出不同速度」，群體模型對個人會有系統性偏差，是本專題改用騎士自己 GPX 的直接依據。

B2 以地形預測移動速度：個人配速模型的類比

登山健行領域有和本專題結構最接近的研究。Wood 等人 [25] 從約兩萬條公開 GPS 軌跡篩出英格蘭與威爾斯 7,636 條（約 88,000 km），以 GLM 用坡度、地表類型與障礙程度預測步行速度，並與 Naismith rule、Tobler hiking function、Campbell et al. 比較。以 50 m 為單位時 GLM 的 RMSE 較低；但換成整條路線時，各模型的平均百分比誤差都在 13.5%–15.5%，沒有一個明顯較好。作者也說明模型只代表平均條件下的平均個人，沒有納入體能、年齡、天氣等個人因素。這兩點都對應本專題：以地形特徵逐段預測可行，但要做整趟預測，還需要個人化資料與區間估計。

B3 騎乘風險：彎道、午後雷雨與預警性封路

彎道與事故風險。 Xin 等人 [26] 以 Florida 2005–2015 年鄉間雙車道公路的 1,601 個事故路段與 16,010 個對照路段做 matched case-control 分析，發現半徑 1,500 ft 以下的非反向急彎對單一機車事故風險最高，其次為急反向彎與中等反向彎；作者也指出騎士在急彎、窄路肩與鋪面不佳處可能有風險補償行為。

台灣午後雷雨。 Lin 等人 [8] 分析 2005–2008 年暖季（5–10 月）綜觀尺度弱時的台灣午後雷雨，結合雷達、閃電、探空與地面觀測，發現平均逐時雨量在當地時間 15–16 時達到高峰，降雨最常出現在山脈較低坡面上一條與山脈平行的狹長帶。也就是說，同一條山路的降雨風險會隨抵達時段與所在高度改變，這是天氣 Agent 需要依「預計抵達各段的時間」查預報，而不是只查出發地天氣的原因。

山區道路預警性封閉。 Yang 等人 [27] 以 2004 年敏督利颱風引發的崩塌訓練 logistic regression，在南投國姓鄉繪製崩塌機率圖，標出颱風期間建議封閉的高風險路段，並以之後颱風造成的實際封路驗證。這類研究提供「降雨與封路有關」的依據，但結果是特定地區的崩塌潛勢，不是全台可即時查詢的封路資料。

2.4 方法比較

Method	Core Idea	Strength	Weakness	Application	Limitation
平均速度／速限換算	路段距離除以平均速度或速限，再加總	簡單、不需訓練資料	忽略彎道、坡度、路口；誤差會累積 [20]	本專題 baseline	無法反映個人與地形差異

Method	Core Idea	Strength	Weakness	Application	Limitation
運行速度迴歸 [23][24]	以道路幾何預測第 85 百分位速度	可解釋，與道路設計規範接軌	只描述群體，對熟悉路線者偏差較大 [24]	彎道設計、速度管理	單點速度，不是整趟時間；機車樣本少
地形 GLM [25]	以坡度與地表類型逐段預測速度	特徵少、可解釋，逐段誤差低於經驗公式	整趟誤差 13.5% – 15.5%，未納入個人因素	健行時間估算	平均個人、平均條件
端對端深度 TTE [20]	整條路徑直接預測，multi-task 同時學子路徑	減少加總誤差	需要大量軌跡（數百萬條）	城市計程車 ETA	城市汽車資料，不提供區間
GNN ETA [3]	supersegment 圖結構加即時與歷史速度	已大規模部署，降低負面 ETA	依賴大量即時車流；冷門道路改用簡單模型	Google Maps	群體平均，未提到個人化與機車
機率式 TTE [21]	低秩多變量高斯，建模行程間相關	輸出分布，可評估不確定性	假設高斯分布	網約車 ETA	城市資料、各 6 天
LLM Agent（ReAct 等）[5]	LLM 自己選工具、蒐集資料、產生計畫	彈性高，能處理自然語言需求	工具誤用、幻覺、無法追蹤多個限制	旅遊規劃 benchmark	GPT-4-Turbo pass rate 0.6%
LLM + critics [17]	LLM 產生，外部 critic 檢查並回饋	不需完整形式化，可逐步修正	提升幅度有限（GPT-3.5 由 0% 到 5%）	旅遊規劃	critic 的涵蓋範圍決定上限
LLM + 形式化求解器 [18]	轉成 SMT 問題交給求解器	成功率 93.9%，能說明無解原因	需要能形式化的限制	多限制規劃	限制以預算、班次為主，沒有時間預測不確定性
檢索增強規劃 [22]	檢索參考行程再由 LLM 調整	改善路線效率與 POI 合理性	參考資料衝突或有雜訊時不穩	城市旅遊行程	以 POI 為中心，不含騎乘時間與天候
本專題	個人 GPX 配速模型（MLR → LightGBM 分位數）+ 多 Agent + 驗證 Agent 重新規劃	預測對個人化、有 P50／P90 區間；數字由工具產生並驗證	只有一位騎士、279 趟資料；風險規則沒有正確答案可驗證	台灣重機旅遊	不宣稱預測事故；封路資料覆蓋有限

技術演進可以歸納為兩條線：時間預估由「加總平均」走向「端對端」、「圖結構」再到「機率分布」，但始終以城市汽車與群體平均為對象；LLM 規劃由「直接生成」走向「外部 critic」、「形式化求解器」與「檢索增強」，但限制條件始終沒有涵蓋依賴個人速度與即時環境的時間可行性。

2.5 Article Summary Table

Ref	Year	Problem	AI Method	Domain Knowledge	Dataset	Findings	Limitation
[20]	2018	城市中任意路徑的旅行時間	DeepTTE：geo-convolution + recurrent + multi-task	路口、號誌使路段時間無法直接相加	兩個城市的大規模計程車軌跡資料集（公開範例資料為成都）	優於當時方法（摘要無具體數字）	需要大量軌跡；城市汽車；無區間
[3]	2021	Google Maps 的 ETA 預測	GNN on supersegments，MetaGradients 訓練	道路等級、歷史與即時車速	Google Maps 生產資料；離線實驗 NYC、LAX、TYO、SGP	Sydney 等城市負面 ETA 降低 40% 以上	只涵蓋約一百萬個 supersegment；未提到個人化、機車、天氣
[21]	2025（arXiv 2024）	機率式旅行時間，考慮行程間相關	ProbETA：低秩多變量高斯 + link representation（empirical Bayes）	天氣與駕駛行為造成行程間相關	成都、哈爾濱網約車 GPS（各 6 天）	MAPE 降低 12.60% 以上，以 CRPS 評估分布	高斯假設；城市資料；無個人化
[5]	2024	LLM Agent 能否完成真實旅遊規劃	ReAct 等 Agent 框架 + 工具	旅遊常識限制與使用者硬限制	1,225 個需求、約四百萬筆沙盒資料	GPT-4-Turbo 兩階段 final pass rate 0.6%	限制以預算、班次、住宿為主；美國國內旅遊
[18]	2025	讓 LLM 嚴謹地解多限制規劃	LLM 轉譯 + SMT／satisfiability 求解器	旅遊限制的形式化	TravelPlanner、國際旅遊與無解問題資料集	TravelPlanner 成功率 93.9%；無解問題修改後可解 81.6%／91.7%	需要限制可形式化；不處理預測的不確定性
[16]	2025	foundation model 的地圖空間推理	30 個 foundation model 評測（文字、API、視覺）	距離、方向、路線、地點知識	700 題，180 個城市、54 國	最佳不超過 67%，落後人類 20% 以上	選擇題形式；只評測不提出改善方法
[23]	2021	機車騎士在雙車道鄉道的運	迴歸型運行速度模型（統	平曲線幾何、照明條件、機	儀器化機車，有經驗騎士自	以少數幾何參數建立實用的	摘要未列騎士人數與誤差；

Ref	Year	Problem	AI Method	Domain Knowledge	Dataset	Findings	Limitation
		行速度	計，非 ML）	車事故比例高	然騎乘（希臘）	機車速度模型	群體模型
[24]	2017	彎道速度模型能否跨州移轉	速度預測與速度差模型（統計）	曲線嚴重度、側向摩擦差、路線熟悉度	SHRP 2 車速資料（Texas → Indiana）	加調整係數可移轉；熟悉者彎道速度較高，模型對其較不準	摘要未提機車；單點速度
[26]	2019	平曲線設計對單一機車事故風險的影響	matched case-control + conditional logistic	曲線半徑、反向曲線、路肩、鋪面	Florida 鄉間雙車道 2005–2015：1,601 案例、16,010 對照	半徑 ≤ 1,500 ft 非反向急彎風險最高	美國資料；CMF 不能直接換算成個人行程風險
[25]	2023	以 GPS 軌跡改善健行速度預測	GLM（坡度、地表、障礙）	Naismith、Tobler、Campbell 等經驗公式	英格蘭與威爾斯 7,636 條軌跡、約 88,000 km	50 m 路段 RMSE 低於經驗公式；整趟各模型誤差 13.5%–15.5%	代表平均個人；未納入體能、天氣
[8]	2011	台灣暖季午後雷雨的時空特性	觀測資料統計分析（非 ML）	海風、山區地形、綜觀尺度弱	2005–2008 暖季雷達、閃電、探空、地面觀測	雨量高峰在 15–16 時，集中在山脈較低坡面	只描述氣候特性，不是逐日預報
[27]	2012	預測颱風崩塌造成的山區道路封閉	logistic regression 崩塌機率模型	崩塌致因與觸發因子	南投國姓鄉，敏督利颱風（2004）崩塌	標出建議封閉路段，與之後颱風的封路相符	單一地區；摘要未報告效能數字；非即時資料

AI 技術 6 篇（[3][5][16][18][20][21]），領域知識 6 篇（[8][23]–[27]）；[17]、[22] 在 2.2 與 2.4 補充演進脈絡。

2.6 既有產品

重機導航 App 已經處理了「找好騎的路」：calimoto 有四種路線設定（含 Winding、Twisty）與衡量彎道程度的 Calimeter，Premium 版提供 TomTom 即時封路資料 [28]；

Kurviger 可調整路線彎曲程度、避開目前的封路與未鋪面道路、產生最長 600 km 的環線並匯入 GPX [29]；REVER 提供路線規劃與離線騎乘紀錄 [30]；Google Maps 2018 年 7 月在台灣推出機車導航 [13]；BMW Motorrad Connected 有彎道路線選項、騎乘紀錄（含傾角）、GPX 匯出、剩餘續航與目前位置天氣 [31]。我們開啟的產品頁面都沒有提到以騎士自己的歷史紀錄預測每段騎乘時間、依各段抵達時間檢查沿途天氣與日落，或在出發前驗證整份計畫是否可行。

2.7 Existing Research → Limitations → Research Gap → Our Project

階段	內容
Existing Research	旅行時間預估已由加總平均發展到端對端、圖神經網路與機率分布 [3][20][21]；LLM 規劃研究證實 LLM 單獨規劃失敗率高，需要外部 critic、求解器或檢索 [5][16]–[18][22]，近期多 Agent 系統開始把天氣、道路距離與營業時間帶進規劃 [15][32][33]；道路與安全研究建立了機車彎道速度、彎道事故風險、台灣午後雷雨與颱風封路的知識 [8][23][24][26][27]；健行研究顯示以地形逐段預測速度可行 [25]。
Limitations	(1) TTE 模型以城市汽車、群體平均為主，需要大量軌跡，沒有處理機車與山區彎道，也沒有個人化 [3][20][21]。(2) 機車速度研究預測的是群體第 85 百分位的單點速度，且對熟悉路線者偏差較大 [23][24]；地形模型在整趟層級仍有 13.5%–15.5% 誤差 [25]。(3) LLM 規劃 benchmark 的限制是預算、班次與 POI，不含依賴個人速度與即時天候的時間可行性 [5][18][22]；多 Agent 系統雖加入環境資料，但對象是城市景點行程，沒有依個人速度推算各點抵達時間 [15][32][33]，而 LLM 本身在距離與路線推理上弱 [16]。(4) 天氣與封路研究是各自獨立的區域分析，沒有接到行程規劃 [8][27]。(5) 既有 App 能找彎路與封路，但頁面上沒有個人化騎乘時間與行前可行性驗證 [13][28]–[31]。
Research Gap	目前沒有看到一個系統同時做到：以單一騎士的歷史軌跡學出含地形與時段特徵的個人配速並給出區間；把配速區間和沿途天氣、日落、封路、加油距離放在同一份計畫裡；再由驗證者檢查計畫中的時間與距離是否一致可行，不行就重新規劃。
Our Project	本專題以騎士自己的 279 趟 GPX 建立路段騎乘時間模型（特徵：彎曲度、坡度、道路等級、時段、天氣），以多元迴歸為 baseline、LightGBM 分位數損失輸出 P50／P90，並和平均速度、Google Maps 預估時間比較，用 MAE、MAPE 與區間覆蓋率評估。Agent 端採多 Agent 分工：規劃、配速、天氣（氣象署預報，依各段抵達時間查詢）、路況與補給（TDX 路

階段	內容
	況、中油與台糖加油站、車輛續航）、驗證；驗證 Agent 檢查日落前回程、時間加總、續航距離與數字出處，不通過就退回重新規劃，對應 [5][17][18] 的「外部驗證」結論。風險部分採氣象署警特報門檻的透明規則，不宣稱預測事故。

3. Deep Research 深度研究

3.1 Q1. 五個核心思維模式

M1. 以最難的路段規劃，不以平均速度規劃

意義： 一趟山路行程的風險和時間誤差集中在少數彎道密集的路段。整趟平均速度會掩蓋這些路段，資深騎士看的是「最難那一段要花多久、能不能安全通過」。

證據： TxDOT 設計手冊整理的研究指出，單車事故在半徑 1,500 ft 以下的彎道約為直線路段的近 5 倍風險，半徑 1,500–3,000 ft 約 2 倍 [34]。英國 Highway Code 要求以「能在可見且淨空的距離內停下」的速度行駛，並提醒鄉間彎道可能比看起來更急 [35]。MSF 100 自然騎乘研究（100 位騎士、約 36.6 萬英里）指出，右彎的事故與近事故風險約為直線的 2 倍，單車事故與近事故有 67% 涉及過彎；這些數字包含近事故，不等於致命事故風險 [36]。Victoria Police 也指出團騎死亡最常見的型態之一是彎道失控 [37]。

如何影響系統設計： 配速分析 Agent 以路段為單位預測，特徵包含曲率、坡度與彎道密度，輸出 P50/P90 而不是單一平均值；地圖依路段上色，讓最難的路段一眼可見；baseline 比較刻意納入「整趟平均速度」，用來證明路段化的必要。

M2. 山區天氣看時間窗，不只看「會不會下雨」

意義： 台灣暖季在綜觀天氣弱時，午後對流有明確的日變化。騎士關心的不是當天降雨機率，而是「我抵達山區那一段時是幾點」。

證據： Lin et al. 分析 2005–2008 年 5–10 月弱綜觀強迫下的台灣午後雷雨，平均時雨量在地方太陽時 15–16 時達高峰，降雨最頻繁的區域是沿山脈走向的低坡帶 [8]。

如何影響系統設計： 天氣 Agent 不查整天預報，而是用配速 Agent 給出的各段預計抵達時間（含 P90）查該時段該地點的預報；若山區路段的 P90 抵達時間落入午後對流時段，風險規則加權並建議提早出發。具體門檻用歷史行程與觀測回測決定，不預設。

M3. 日光與騎乘時數是硬限制，不是偏好

意義： 天黑後山路的視距與路面辨識度下降，疲勞又會削弱判斷力。資深騎士把「天黑前離開山區」和「定時休息」當成不可談判的條件。

證據： 氣象署定義民用暮光終為太陽中心低於地平線 6 度，之後一般戶外活動通常需要人工照明；資料以縣市、逐日提供，含日沒與民用暮光終欄位 [38]。NSW 政府列出騎士疲勞的成因包括冷熱天氣、噪音、強風與脫水，並建議即使不覺得累也要休息 [39]。英國 DfT 的騎士疲勞報告據報導指出 14–16 時的午後低谷是高風險時段之一，結論是要更規律休息 [40]（partial）。

如何影響系統設計： 驗證 Agent 的硬規則：整趟 P90 回程時間不得晚於民用暮光終或騎士設定的更早時間，違反就退回規劃 Agent；跨對話記憶保存騎士的最長連續騎乘時數，規劃時自動插入休息點，休息時間計入總時程。

M4. 補給以「到達時有沒有開」規劃，不只看距離

意義： 山區加油站間距長，部分站點營業時間有限。只檢查「續航 > 站距」會漏掉清晨出發或傍晚回程時加油站已關的情況。

證據： 中油加油站服務資訊開放資料的欄位包含「營業中」與「營業時間」，另有經緯度與油品別 [41]。

如何影響系統設計： 路況與補給 Agent 先由配速 Agent 取得抵達各站的時間，再用營業時間過濾可用站點；驗證 Agent 檢查任兩個「抵達時有營業」的站點之間距離不超過扣除安全餘量的續航。車系油箱與油耗放在知識庫並附出處。

M5. 山區道路狀態是動態的，官方會預防性封閉

意義： 南橫等山區省道會在豪雨前後預警性封閉，解封取決於現場狀況。昨天能走的路，今天不一定能走；行程要有折返點與替代方案。

證據： 2025 年 9 月樺加沙颱風外圍環流使台東山區達超大豪雨警戒（24 小時累積雨量 500 mm 以上），台 20 線向陽至初來路段（149K+110 – 199K+000）預警封閉 [10]。

2026 年 6 月台 20 線寶來二橋至桃源區公所路段因雨預警封閉，雨勢趨緩、排除零星路況後才解除 [42]。兩篇報導都沒有提到固定的雨量封路門檻。

如何影響系統設計： 系統不自行發明封路門檻；路況與補給 Agent 讀 TDX 即時路況，封閉資訊無法以機器取得時，計畫標示「出發前需人工確認」並附公路局來源。規劃 Agent 對每條山區路線預先產生折返點與替代路線。

3.2 Q2. 三個最重要的專業爭論

C1. LLM Agent 能否自我修正規劃，或必須依賴外部驗證器

- **觀點 A：** LLM 透過反思與自我批評就能改善結果。
- **觀點 B：** LLM 的自我檢查不可靠，可行的計畫要靠外部、可靠（sound）的驗證器。
- **雙方最有力的證據：** A 方：Reflexion 以語言化的自我反思回饋，在 HumanEval 達 91% pass@1，高於 GPT-4 原報告的 80% [43]。B 方：TravelPlanner 中 GPT-4 的成功率只有 0.6% [5]；以 GPT-4 同時生成與驗證計畫時，自我批評反而降低表現，且 LLM 驗證器產生大量偽陽性 [44]；LLM-Modulo 加上外部批評器後，GPT-4 Turbo 表現約提升 4.6 倍 [17]；把旅遊規劃轉成可滿足性問題交給求解器，成功率達 93.9%，同文指出 o1-preview 約 10% [18]。
- **目前共識：** 對有硬限制（時間、預算、距離）的規劃，外部可靠驗證器是目前最有效的做法；自我反思在有客觀回饋（例如測試結果）的任務中較有效。
- **尚未解決的問題：** 風險、舒適度這類軟性限制很難寫成可靠驗證器；驗證器沒涵蓋到的錯誤仍會通過。
- **對本專題的意義：** 驗證 Agent 用程式規則檢查時間、續航、日落與數字來源，不讓 LLM 自己判斷「計畫是否可行」；消融實驗（只用 LLM vs 完整 Agent）直接檢驗這個爭論。

C2. 配速模型應個人化，還是用可轉移的通用模型

- **觀點 A：** 速度選擇因人而異，需要用個人資料訓練。
- **觀點 B：** 通用的彎道速度模型經校準就能跨地區使用，個人資料太少反而不穩。
- **雙方最有力的證據：** SHRP2 資料的研究同時支持兩邊：德州建立的速度差模型乘上調整係數後可用在印第安納州（B）；但熟悉路線的駕駛在彎道中點的 85 百分位速度較高，且模型對不熟悉路線的駕駛預測較準（A）[24]。TxDOT 也

指出機車過彎行為與汽車不同：入彎減速、車道內橫移、出彎加速 [34]，代表汽車模型不能直接套用在機車。

- **目前共識：** 群體模型經校準可以轉移；個人熟悉度是主要的變異來源，通用模型對熟悉路線的騎士誤差較大。
- **尚未解決的問題：** 需要多少趟個人資料才夠；騎士配速隨時間漂移；個人模型在沒騎過的路線（冷啟動）表現如何。
- **對本專題的意義：** 以個人 GPX 訓練，baseline 包含通用估計（Google Maps、速限換算）；驗證採依行程分組與時間外推，並把「熟悉／不熟悉路線」分開報告誤差。

C3. ABS 等電子輔助的安全效益，會不會被風險補償抵銷

- **觀點 A：** ABS 實質降低事故，效益不是自我選擇造成的。
- **觀點 B：** 騎士會把安全裕度換成更快的速度，總體效益被稀釋。
- **雙方最有力的證據：** A 方：IIHS 2021 年研究顯示有 ABS 的機車致命事故率低 22%，旅行車型約低 25% [45]；HLDI 2014 年發現高風險騎士選 ABS 的比例不低於低風險騎士且同樣受益，自我選擇無法解釋效果 [46]；HLDI 2025 年更新顯示 ABS 使碰撞理賠頻率下降 25% [47]。B 方：風險補償理論代表人物 John Adams 認為 ABS 的效益會被騎士當成性能消耗掉；評論文章引用英國 2013–2017 年大型機車死亡數大致持平，即使 ABS 已強制 [48]（partial，屬總體統計，干擾因素多）。
- **目前共識：** ABS 的事故降低效果有大量資料支持；機車騎士的風險補償缺少直接量測，目前多為理論與總體數字推論。
- **尚未解決的問題：** 沒有研究直接比較 ABS 與非 ABS 騎士的實際路上速度；彎道 ABS、循跡控制等新輔助的行為影響未知。
- **對本專題的意義：** Copilot 本身也是一種安全輔助，可能讓騎士更晚出發、更貼近極限。系統因此以 P90 而不是 P50 判斷是否趕得上日落，不因車輛有 ABS 而放寬風險規則，並在回答中清楚說明不確定性。

3.3 Q3. 十個深度理解問題

#	類型	問題	好答案的重點
1	Why	為什麼整趟平均速度不適合用來判斷能否天黑前回家？	風險與時間誤差集中在彎道密集的山區路段 [34]。平均值會掩蓋最慢那一段，而天黑時人可能正好

#	類型	問題	好答案的重點
			在最難的路段上；要用路段化預測加 P90。
2	What-if	如果配速模型的 P50 很準，但 P90 區間覆蓋率只有 60%，會發生什麼？	系統會低估晚歸的機率，日落硬規則形同失效。好答案會提到用覆蓋率當評估指標，並以分位數損失或校準修正。
3	Trade-off	預防性封路的資訊沒有機器可讀 API，系統要「保守地全部警示」還是「只警示有資料的路段」？	全部警示會造成警示疲乏，只警示有資料的會漏報。合理做法是區分「已知封閉」「狀態未知需人工確認」兩級，並附公路局來源 [10][42]。
4	Failure Case	驗證 Agent 全部通過，計畫還可能在哪些地方出錯？	驗證只檢查有寫成規則的硬限制，例如時間、續航、日落 [17]。路面碎石、臨時施工、騎士當天身體狀況都不在規則內；所以要有折返點並標示驗證範圍。
5	Evidence	「右彎風險較高」這個說法的證據強度如何？能直接用在台灣嗎？	MSF 100 原始論文 [36] 的數字包含近事故，樣本是美國 100 位騎士。台灣同為靠右行駛，方向上可比，但道路幾何與交通組成不同，只能當假設，要用自己的 GPX 檢查。
6	Comparison	個人配速模型和 Google Maps 預估時間，各自在什麼情境比較準？	個人模型在騎過的路線、休閒騎乘情境應較準，因為熟悉度會改變速度 [24]。Google Maps 有即時車流，塞車路段可能較準；沒騎過的路線個人模型可能退化。
7	Design Decision	為什麼驗證交給程式規則，不讓另一個 LLM 當驗證者？	LLM 自我驗證有大量偽陽性，甚至降低規劃表現 [44]；外部可靠驗證器在 TravelPlanner 類任務效果明顯 [17][18]。LLM 負責理解與解釋，數字一律來自工具輸出。
8	Real-world Scenario	週六團騎南橫，朋友騎得比你快，系統該怎麼規劃？	團騎中試圖跟上是可能的致命因素 [37]。計畫應以隊伍中最慢者的配速估計，設集合點，並提醒各自以自己的速度騎。

#	類型	問題	好答案的重點
9	What-if	如果出發當天早上下過雨，但預報下午轉晴，計畫要怎麼調整？	雨後路面與落石風險未必隨天氣轉晴消失，南橫封閉也是雨勢趨緩後才視路況解除 [42]。應先確認封閉狀態、降低山區路段配速假設並重算日落餘裕。
10	Trade-off	為了避開午後對流提早出發，代價是什麼？	清晨氣溫低、加油站可能未營業 [41]，疲勞也可能提早累積 [39]。好答案要說明這是多目標權衡，系統應比較不同出發時間的方案，而不是只給單一答案。

4. Proposed Scheme 系統設計

4.1 研究目標（PA）

本專題要建立一位重機旅遊規劃代理人，回答騎士出發前最常問、也最容易判斷錯的三個問題：

1. 這趟路以**我自己的騎法**要騎多久？最晚幾點會回到家？
2. 依各路段的**預計抵達時間**，天氣、日照和路況是否允許？
3. 依續航和加油站營業時間，**哪裡加油**才不會沒油？

正式問題定義：給定起點、路線（或途經點）、出發日期、騎士限制（最晚回程時間、最長騎乘時數），以及騎士自己的歷史行程，系統要輸出一份**可行**的行程計畫，包含建議出發時間、各段預計抵達時間的範圍（P50 / P90）、加油點和風險說明；若不存在可行計畫，要說明哪一個條件無法滿足。

4.2 理論與技術基礎（PB）

基礎	用在本專題	來源
路段式旅行時間估計：整趟時間由各段時間組成	配速模型以路段為單位預測再加總	DeepTTE [20]、Google Maps ETA [3]
機率式旅行時間：輸出分佈而非單點	預測 P50 / P90，而不是單一時間	ProbETA [21]
地形特徵預測移動速度	用坡度、彎道等地形特徵預測個人速度	登山配速 GLM [25]、機車速度模型 [23][24]
LLM 規劃需要外部驗證	LLM 負責規劃，驗證交給確定性的工具	TravelPlanner [5]、LLM+SMT [18]、LLM-Modulo [17]
山區午後對流的時空分佈	依預計抵達時間查天氣，避開午後高峰	Lin et al. [8]
山區道路因降雨封閉	路況與封路風險規則	Yang et al. [27]

4.3 問題成因與解法（PC：Cause → Mechanism → Solution）

成因	機制	解法
一般導航的預估時間是群體平均，不知道這位騎士在彎道多的山路騎多快 [3][24]	個人差異在彎道和坡道最大，整趟平均速度會掩蓋最難的路段 [34]	**個人配速模型**：以騎士自己的 GPX 訓練，逐段預測時間，並輸出 P50 / P90 區間
天氣、日照、加油、路況分散在不	規劃時看的是「出發時」的天氣，	**多 Agent 分工**：配速 Agent 先算出

成因	機制	解法
同來源，騎士要自己換算時間	不是「抵達該路段時」的天氣 [8]	各段抵達時間，天氣、路況與補給 Agent 再依那個時間查詢
LLM 自己做時間與距離計算不可靠 [5][16]	長鏈推理中的數字錯誤不會被發現	**驗證 Agent**：以確定性規則檢查整份計畫，不通過就退回重新規劃 [17][18]

4.4 系統架構（PD、PG）

架構依作業規範的 ①–⑧ 模組編號：

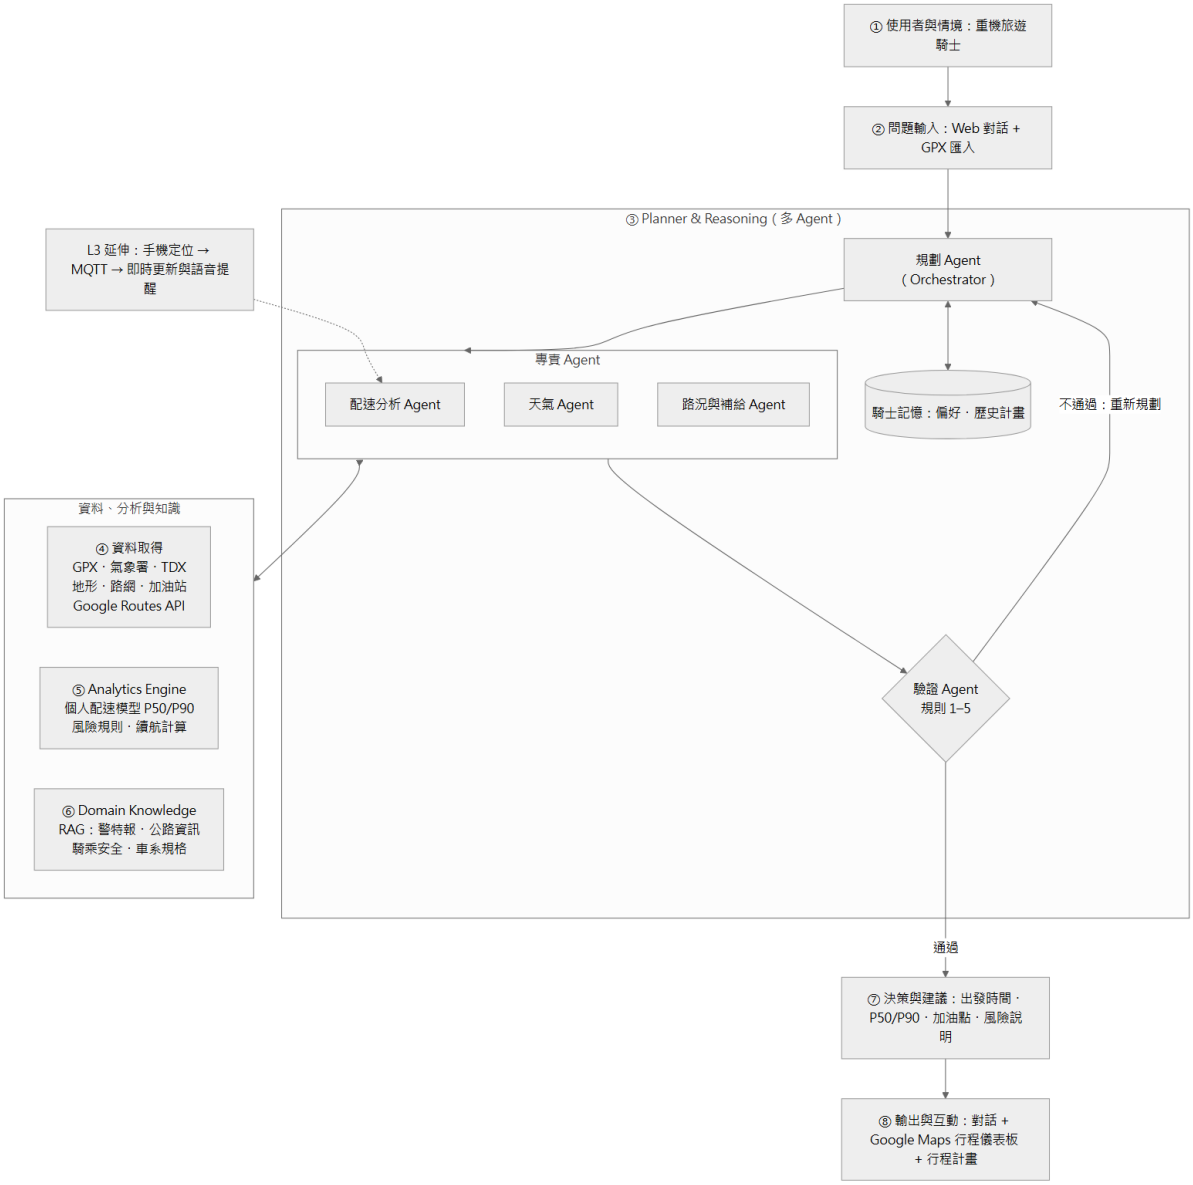


圖 1　系統架構（依作業規範 ①–⑧ 模組編號）

模組說明

編號	模組	內容
①	使用者與情境	在台灣騎重機旅遊的騎士；情境為行程規劃、出發前檢查天氣與路況、油量與加油點；L3 延伸為騎乘中提醒
②	問題輸入	Web 對話介面；用地名描述行程，或在地圖上選點；匯入 GPX 建立與更新個人配速
③	Planner & Reasoning	五個 Agent 分工（見 4.4.1）；驗證不通過就重新規劃；記住騎士偏好與過去計畫
④	資料取得	自己的 GPX、氣象署、TDX、內政部地形（DTM）、OpenStreetMap、中油加油站、Google Maps Routes API
⑤	Analytics Engine	個人配速模型（P50 / P90）、天氣與路況風險規則、續航與加油站檢查、日照檢查；全部是確定性的 Python 工具
⑥	Domain Knowledge	知識庫檢索：氣象署警特報說明、公路局行車資訊、騎乘安全資料、BMW 車系規格（油箱、油耗）、相關研究；回答附出處
⑦	決策與建議	建議出發時間、各段抵達時間範圍、加油點、風險排序與理由；不可行時說明原因與替代方案
⑧	輸出與互動	對話回答；Google Maps 行程儀表板（路段依時間與風險上色、加油站、日落時間）；可下載的行程計畫

4.4.1 多 Agent 分工

Agent	輸入	輸出	工具
規劃 Agent	使用者問題、騎士記憶	任務分派、彙整後的計畫草案	知識庫檢索
配速分析 Agent	路線、出發時間、騎士 ID	各段 P50 / P90 時間、各點 P50 與 P90 預計抵達時刻（4.6）	路線切段、地形特徵、配速模型、Google 預估時間
天氣 Agent	各段位置與 P50 / P90 預計抵達時刻	各段降雨機率、溫度、警特報；民用暮光終	氣象署預報、觀測、日出日沒資料
路況與補給 Agent	路線、各點 P90 預計抵達時刻、車型	路況事件、可用加油站（含營業時間）、續航檢	TDX、中油加油站、車系規格

Agent	輸入	輸出	工具
		查	
驗證 Agent	完整計畫草案	通過，或違反的規則清單	驗證規則（4.6）

4.4.2 對應課程框架

課程專題說明以三個框架描述一位合格的領域代理人：③ 的標準 Agent Workflow、④ 的六大能力、⑨ 的實作 Level。本專題的對應如下。

Agent Workflow（③-1 至 ③-6）

階段	本專題的做法	負責
③-1 Understand 理解需求	取出起訖點、路線、日期、最晚回程時間等限制；缺資訊就追問	規劃 Agent
③-2 Plan 規劃推理	決定工具順序，並產生候選出發時間	規劃 Agent
③-3 Acquire 取得資料	自己的 GPX、氣象署預報與觀測、TDX 路況、地形與路網、加油站	配速、天氣、路況與補給 Agent
③-4 Analyze 資料分析	個人配速模型（P50 / P90）、風險規則、續航計算	配速分析 Agent 與 Analytics Engine
③-5 Generate 生成建議	經驗證 Agent 檢查後，產生出發時間、加油點與風險說明；不可行時提出替代方案	驗證 Agent、規劃 Agent
③-6 Interact 互動呈現	對話回答、Google Maps 行程儀表板、可下載的行程計畫	規劃 Agent

六大能力（④）

能力	本專題的做法
TALK 會對話	多輪對話，主動追問缺少的條件
KNOW 專業知識	知識庫檢索氣象署警特報說明、公路局行車資訊、騎乘安全資料、車系規格與相關研究，回答附出處
SENSE 取得資料	騎士自己的 GPX 行程（約 1 秒一點）與政府開放資料；L3 加上騎乘中的手機定位串流
ANALYZE 資料分析	分位數梯度提升樹預測路段時間與區間，並和多元迴歸、平均速度、Google 預估時間比較
THINK 自主決策	多 Agent 分工、驗證不通過就重新規劃、記住騎士偏好
SHOW 呈現成果	依路段時間與風險上色的地圖、時間軸、行程計畫；L3 加上語音提醒

實作 Level（⑨）

Level	在本專題的內容	範圍
L1 LLM + Data	對話介面、讀取 GPX 與開放資料、Python 分析、圖表	包含在 L2 內
L2 Knowledge Agent	知識庫檢索、多 Agent 多步推理、驗證與重新規劃	承諾完成
L3 IoT Autonomous Agent	騎乘中手機定位經 MQTT 回傳，即時更新抵達時間並語音提醒	延伸，期末視進度

4.5 核心元素與符號（PE）

符號	意義
$r = (s_1, \dots, s_n)$	一條路線切成 n 個路段（約 0.5–2 km，或依道路切分）
$\boldsymbol{x}_i$	路段 s_i 的特徵：曲率（每公里轉角、最小半徑）、坡度（DTM）、道路等級、公路局急彎與陡坡標記、時段、天氣、已騎里程
L_i	路段長度
$\hat{t}_i^{(q)} = \exp\big(f_q(\boldsymbol{x}_i)\big)$	個人配速模型對路段 i 移動時間第 q 分位數的預測（$q = 0.5, 0.9$ 即 P50 / P90 時間）；f_q 以對數移動時間為目標訓練
d	出發時間
$\mathrm{ETA}_k^{(q)}$	抵達第 k 個路段終點的第 q 分位數時刻（$k = 1, \dots, n$）
$T^{(q)}$	整趟第 q 分位數的騎乘時間（含休息），$T^{(q)} = \mathrm{ETA}_n^{(q)} - d$
T_{dusk}	當日民用暮光終（氣象署資料）[38]
T_{user}	騎士設定的最晚回程時間
R	車輛續航（油箱容量 × 油耗，取自車系規格與騎士資料）
G	沿線加油站集合，含位置與營業時間

4.6 數學模型（PF）

配速模型。 以騎士自己的行程訓練，目標是路段移動時間的對數 $y_i = \log t_i$。分位數在單調遞增變換下不變，所以對數時間的第 q 分位數取指數就是時間的第 q 分位數：

$$\hat{t}_i^{(q)} = \exp\big(f_q(\boldsymbol{x}_i)\big), \qquad q \in \{0.5,\ 0.9\}$$

不以速度為目標再換算成時間：時間 $t = L/v$ 是速度的遞減函數，速度的第 0.9 分位數對應的是時間的第 0.1 分位數，若用速度的 P90 換算，P90 時間會變成最樂觀的估計，日照規則就會失效。

- Baseline：平均速度、速限換算、Google Maps 兩輪車預估時間。
- 模型一：多元迴歸（課程 L6）。
- 模型二：LightGBM，以分位數損失（pinball loss）分別學 $q = 0.5$ 與 $q = 0.9$：$\mathcal{L}_q(y, \hat{y}) = \max(q(y - \hat{y}),\ (q - 1)(y - \hat{y}))$

整趟區間。 各段 P90 直接相加會高估整趟 P90（各段誤差不會同時最差）。因此整趟以各段 P50 相加，再用依行程分組的保留資料，校正「整趟實際時間 − 整趟預測」殘差的第 90 百分位（conformal 校正），得到整趟 P90：

$$T^{(0.9)} = \sum_i \hat{t}_i^{(0.5)} + B + \hat{c}_{0.9}$$

其中 B 是休息時間，$\hat{c}_{0.9}$ 是校正量。

各點抵達時刻。 天氣、補給與驗證規則需要的是「抵達沿線某一點」的時刻，不只是整趟時間。P50 抵達時刻由各段 P50 時間累加；P90 抵達時刻把整趟校正量 $\hat{c}_{0.9}$ 依已騎里程比例分攤到該點：

$$\mathrm{ETA}_k^{(0.5)} = d + \sum_{i \le k} \hat{t}_i^{(0.5)} + B_k, \qquad \mathrm{ETA}_k^{(0.9)} = \mathrm{ETA}_k^{(0.5)} + \hat{c}_{0.9} \cdot \frac{\sum_{i \le k} L_i}{\sum_i L_i}$$

B_k 是第 k 段之前已排定的休息時間。配速 Agent 把 $\mathrm{ETA}_k^{(0.5)}$ 與 $\mathrm{ETA}_k^{(0.9)}$ 一併交給天氣與路況與補給 Agent；各段的 P90 時間 $\hat{t}_i^{(0.9)}$ 只用於地圖上色與找出最難的路段，不加總。

可行性限制（驗證 Agent 的硬規則）：

1. 日照：$d + T^{(0.9)} \le \min(T_{\text{dusk}}, T_{\text{user}})$
2. 續航：任兩個相鄰補給點（含起點）之間的距離 $\le R \times (1 - m)$，m 為安全餘裕；且抵達該加油站的 P90 時刻 $\mathrm{ETA}_k^{(0.9)}$ 落在其營業時間內
3. 天氣：路段的抵達時段 $[\mathrm{ETA}_i^{(0.5)}, \mathrm{ETA}_i^{(0.9)}]$ 與大雨以上警特報範圍重疊時，該段標為高風險；高風險段不得位於日照限制最緊的最後一段
4. 路況：路段有 TDX 封閉或管制事件時，計畫不可行

5. 數字可追溯：回答中的每個時間、距離、機率都必須出現在工具輸出中

決策問題。 在可行的出發時間集合中，選擇讓「回程餘裕」最大、且高風險路段最少的出發時間：

$$d^* = \arg\max_{d \in \mathcal{D}_{\text{feasible}}} \left(\min(T_{\text{dusk}}, T_{\text{user}}) - (d + T^{(0.9)}) \right) \quad \text{s.t. 規則 1–5}$$

$\mathcal{D}$ 是候選出發時間（例如每 30 分鐘一個）。若 $\mathcal{D}_{\text{feasible}}$ 為空，回報違反的規則並提出替代方案（縮短路線、提前出發、改日）。

4.7 處理流程（PI：Flowchart）

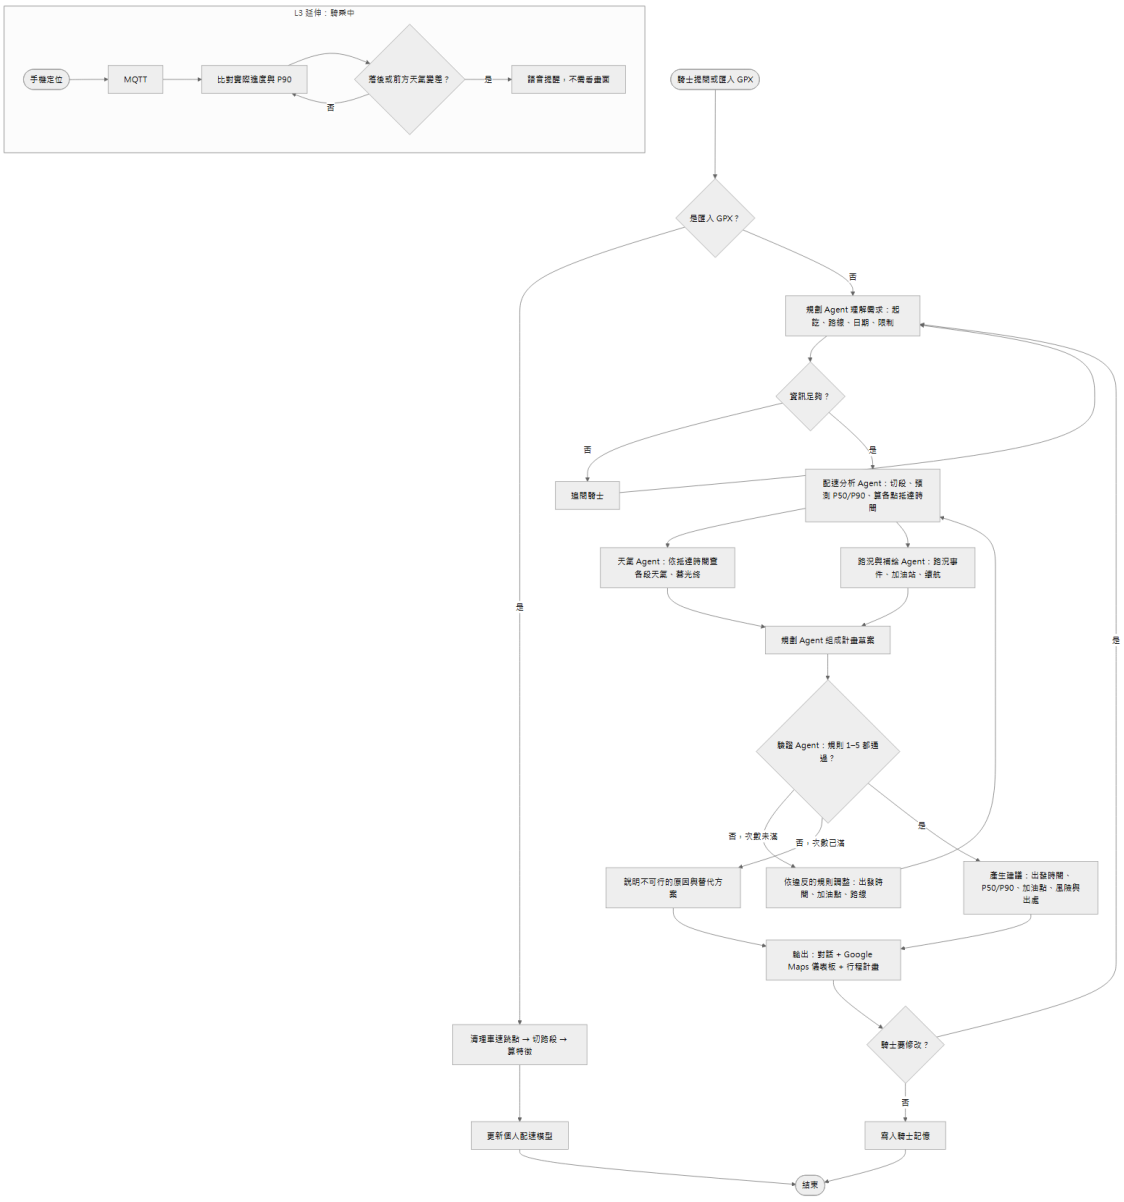


圖 2　處理流程

例外處理：外部 API 失敗時，該 Agent 回報「資料不可用」，驗證 Agent 將相關規則視為未通過並在回答中說明，不以猜測補值。

4.8 核心演算法（Pseudocode）

```
Algorithm 1: Moto Touring Copilot — Plan with Verification
Input : rider query Q, rider id u, trip store S_u, knowledge base KB
Output: feasible trip plan P with ranges and citations, or an infeasibility report
```

```
ctx ← UNDERSTAND(Q, MEMORY(u))                ▷ origin, route, date, T_user, max hours
if MISSING(ctx) ≠ ∅ then return ASK_RIDER(MISSING(ctx))
route ← BUILD_ROUTE(ctx)                      ▷ waypoints → road segments s_1..s_n
X ← SEGMENT_FEATURES(route)                   ▷ curvature, DTM grade, road class, flags
D ← CANDIDATE_DEPARTURES(ctx)                 ▷ e.g. every 30 min
attempts ← 0 ; best ← ∅
repeat
    for each d in D do
        (t50, t90, ETA50, ETA90) ← PACE_AGENT(X, d, u)   ▷ segment times, ETAs (4.6)
        T90 ← ETA90[n] − d                    ▷ = Σ t50 + BREAKS + c_0.9
        W ← WEATHER_AGENT(route, ETA50, ETA90)    ▷ forecast, warnings, T_dusk
        F ← SUPPLY_AGENT(route, ETA90, VEHICLE(u)) ▷ stations (ETA90), range, events
        plan ← ORCHESTRATOR_COMPOSE(d, t50, t90, T90, W, F, SEARCH(KB, W, F))
        (ok, violations) ← VERIFY(plan)           ▷ rules 1–5, numbers traceable
        if ok and SLACK(plan) > SLACK(best) then best ← plan
    if best = ∅ then
        ctx ← REPLAN(ctx, violations) ; attempts ← attempts + 1
until best ≠ ∅ or attempts ≥ MAX_ATTEMPTS
if best = ∅ then return INFEASIBILITY_REPORT(violations, ALTERNATIVES(ctx))
SAVE_MEMORY(u, ctx, best)
return RENDER(best)                           ▷ chat + Google Maps dashboard + plan file
```

```
Algorithm 2: Personal Pace Model Update
Input : new GPX trips G, existing trip store S_u
Output: updated models f_0.5, f_0.9 and conformal correction c_0.9

for each g in G do
    g ← TRIM_ENDS(g)                          ▷ remove home/work ends for privacy
    g ← CLEAN_SPEED(g)                        ▷ drop GPS spikes, smooth
    g ← SPLIT_MOVING(g)                       ▷ separate moving time from stops
    S_u ← S_u ∪ SEGMENTS(g)                   ▷ features from DTM, OSM, weather history
folds ← GROUP_KFOLD(S_u, by = trip)
f_0.5, f_0.9 ← FIT_QUANTILE_GBM(S_u, folds)   ▷ y = log moving time; MLR baseline
c_0.9 ← Q90(trip_actual − trip_predicted on held-out trips)
return f_0.5, f_0.9, c_0.9
```

4.9 範例（PJ）

以下為說明流程用的假設情境，數值為示意，不是實驗結果。

1. 騎士問：「週六新竹出發，走南橫當天來回，晚上七點前要回到家，幾點出發？」
2. 規劃 Agent 追問：「從哪一端進南橫？」騎士回答後，路線確定。
3. 配速分析 Agent 把路線切成數百個路段，依騎士過去在彎道山路的速度預測各段時間，並對每個候選出發時間算出各點預計抵達時間。
4. 天氣 Agent 發現依預計抵達時間，最高的山區路段會落在午後對流時段；路況與補給 Agent 找出山區前最後一個營業中的加油站。
5. 驗證 Agent 檢查：較晚的出發時間違反日照規則；某個出發時間的 P90 抵達加油站時間超過其營業時間。
6. 最後建議一個可行的出發時間，說明理由（避開山區午後對流、在暮光終前回到家、指定加油點），並在 Google Maps 上用顏色標出各段時間與風險。

4.10 資料與工具

類別	來源	用途	狀態
自己的行程	BMW Motorrad Connected 匯出的 GPX，279 趟	訓練與驗證配速模型	已檢查一趟：約 1 秒一點，有經緯度、高度、時間
天氣	氣象署開放資料 API；CODiS 歷史觀測	預報、警特報、民用暮光終；訓練時的歷史天氣	API 文件已查證
路況	交通部 TDX 省道即時路況	道路事件	已查證資料集；道路阻斷沒有找到機器可讀來源
地形與路網	內政部 20 m DTM、OpenStreetMap	坡度、曲率、道路等級	需使用 DTM 而非 DSM
公路幾何	公路局 GIS 開放資料	急彎、陡坡、速限	已查證
補給	中油加油站資料	位置、營業時間	已查證（最後更新 2024-05）
地圖與 baseline	Google Maps Platform（Maps JavaScript、Routes API）	顯示地圖；兩輪車預估時間	Routes API 兩輪車覆蓋清單有列台灣；費用待確認
知識庫	氣象署、公路局、騎乘安全資料、車系規格、論文	RAG 檢索	待蒐集
分析工具	pandas、scikit-learn、statsmodels、LightGBM、OSMnx、地圖比對工具	特徵與模型	—
Agent	支援工具呼叫的 LLM API（供應商待定）、自行撰寫的多 Agent 迴圈	規劃與解釋	—
介面	Streamlit + Google Maps	Web 對話與儀表板	—
L3 延伸	手機定位 App、MQTT	騎乘中進度與提醒	不在車上加裝任何東西

類別	來源	用途	狀態
	（家中 RPi 5）		

4.11 評估計畫（PL）

依 CRISP-DM 的 Evaluation 階段設計。以下是預計進行的實驗，**目前沒有結果**。

實驗	問題	方法	指標
E1 配速模型	個人配速模型比一般導航的時間估計準嗎？	平均速度、速限換算、Google 兩輪車預估時間 vs 多元迴歸 vs LightGBM；依行程分組交叉驗證，再加上以最新行程為測試集的時間外推	路段與整趟的 MAE、MAPE；整趟 P90 覆蓋率
E2 驗證 Agent 與消融	外部驗證能不能提高計畫的可行率？	準備約 20–30 題規劃問題。每題事先以獨立腳本（不經 Agent 與其工具）算出 oracle：當日民用暮光終、沿線加油站營業時間、該日已知的管制事件、以實際騎過的行程為準的各段時間。比較只用 LLM、LLM + 知識庫、完整 Agent（工具 + 驗證）三組；另以完整 Agent 為基準，逐一拿掉個人配速模型（改用 Google 預估時間）、天氣資料、路況資料，量化各模組的貢獻	oracle 違規率（計畫違反任一 oracle 事實的比例）、回程時間對 oracle 的誤差、計畫中的數字與 oracle 一致率；另報告各組的拒答／不可行報告率與候選出發時間數
E3 風險規則	風險規則是否抓得到歷史封路日？	以歷史封路紀錄回測規則；敏感度分析	命中率、誤報率；不宣稱預測事故
E4 案例研究	對騎士有沒有實際價值？	2–3 個完整情境；以過去的實際行程回測「如果當時用這個工具，預測的回程時間和實際差多少」	質性說明與回測誤差

E2 不以驗證 Agent 自己的規則 1–5 當指標：完整 Agent 只會輸出通過這些規則的計畫，用同一套規則評分會變成循環驗證；只用 LLM 的對照組沒有工具輸出，規則 5 也必然不通過。改以獨立算出的 oracle 評分，三組才站在同一個基準上；同時報告拒答率，避免完整 Agent 以拒答換取低違規率。

預期成果： 個人配速模型在彎道多的山區路段，整趟時間誤差低於一般導航的估計；完整 Agent 的計畫對獨立 oracle 的違規率低於只用 LLM 的版本，拿掉個人配速或天氣、

路況資料後違規率或時間誤差上升。系統輸出的是可解釋的建議，例如「此段預計 14:20 抵達，該時段有大雨特報，建議 13:30 前通過或改走替代路線」，而不是單一的預估時間。本專題不宣稱能降低事故率，因為沒有因果證據。這些是待驗證的假設。

4.12 主要創新（PK）

1. **以騎士自己的歷史行程學個人配速，並輸出區間。** 現有研究多為群體平均或城市汽車 [3][20][24]，本專題以單一騎士的山路資料預測，並用 conformal 校正整趟 P90。
2. **依「抵達時間」整合天氣、日照與補給。** 天氣與加油站查詢是依各段預計抵達時間，而不是出發時間。
3. **規劃與驗證分離的多 Agent 架構。** LLM 負責理解與規劃，確定性的驗證規則檢查可行性並觸發重新規劃，回應 LLM 規劃不可靠的研究結果 [5][17][18]。
4. **以消融實驗量化 Agent 的價值。** 以獨立 oracle 判定可行性，直接比較只用 LLM 與完整 Agent 的計畫違規率。

4.13 可行性與限制

可行性依據：

- 資料：279 趟 GPX 已在手上；實際檢查一趟，取樣約 1 秒一點，可算出怠速、停車、加速、車速等特徵。氣象署、TDX、地形、公路局、加油站、Google 兩輪車路線都已確認可取得。
- 方法：同一套「行程切段 → 特徵 → 多元迴歸 vs 梯度提升樹 → 依分組交叉驗證」的流程，已在公開汽車資料集 VED 上跑通（不同資料集，僅證明流程可行，不是本題結果）。
- 範圍：承諾 L2；L3 為延伸。

限制：

限制	影響	對策
只有一位騎士（n = 1）	模型不能推廣到其他人	定位為個人化；方法對任何匯入 GPX 的騎士適用
道路阻斷沒有機器可讀來源與歷史紀錄	路況規則的即時性與回測受限	先用 TDX 即時路況；阻斷資料列為延伸
風險評分沒有正確答案	不能宣稱預測事故	規則透明、回測、敏感度分析
GPX 高度雜訊、車速跳點	坡度與速度誤差	坡度改用 DTM；車速平滑
GPX 含住家位置	隱私	原始檔不進 repo；裁掉頭尾、只公

限制	影響	對策
		開衍生資料

參考文獻 References

[1] 交通部路政及道安司，〈道安資訊查詢網：事故位置與機車死傷統計（112－114 年為初估值）〉，資料更新 2026-10-27。https://roadsafety.tw/AccOrder?Order=Ieok26&type=%E4%BA%8B%E6%95%85%E4%BD%8D%E7%BD%AE ；https://roadsafety.tw/AccOrder?Order=Age&type=%E6%A9%9F%E8%BB%8A

[2] 交通部公路局，《中華民國 114 年交通部公路局統計年報》，表 26 機動車輛登記數、表 27 新車領牌數，2026。https://ws.thb.gov.tw/001/Upload/436/relfile/13775/5693/fd88dd50-c215-4973-8db5-33f0c3e9510e.pdf

[3] A. Derrow-Pinion, J. She, D. Wong, O. Lange, T. Hester, L. Perez, M. Nunkesser, S. Lee, X. Guo, B. Wiltshire, P. W. Battaglia, V. Gupta, A. Li, Z. Xu, A. Sanchez-Gonzalez, Y. Li, P. Veličković, "ETA Prediction with Graph Neural Networks in Google Maps," *Proceedings of the 30th ACM International Conference on Information and Knowledge Management (CIKM 2021), Applied Research Track*, 2021. https://arxiv.org/abs/2108.11482

[4] Henges, K., "6 Popular Motorcycle Apps For Finding Routes And Tracking Rides," SlashGear, 2025-01-13. https://www.slashgear.com/1755865/motorcycle-apps-find-routes-track-rides

[5] J. Xie, K. Zhang, J. Chen, T. Zhu, R. Lou, Y. Tian, Y. Xiao, Y. Su, "TravelPlanner: A Benchmark for Real-World Planning with Language Agents," *Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*, 2024. https://arxiv.org/abs/2402.01622

[6] 胡瑞玲，〈交通死亡降幅龜速 去年奪 2858 命僅降 3.1%未達標〉，聯合報，2026-03-12。https://udn.com/news/story/7266/9375833

[7] 聯合新聞網，〈政策又跳票？交通事故死亡數去年共奪 2858 命 降幅僅 3.1%〉，2026-03-12。https://udn.com/news/story/7266/9377125 ；TVBS 新聞網，〈台灣 2025 年交通事故死亡人數 2858 人，降幅僅 3.1% 且 4 縣市有攀升跡象〉，2026-04-14。https://cars.tvbs.com.tw/life/315916

[8] P.-F. Lin, P.-L. Chang, B. J.-D. Jou, J. W. Wilson, and R. D. Roberts, “Warm Season Afternoon Thunderstorm Characteristics under Weak Synoptic-Scale Forcing over Taiwan Island,” *Weather and Forecasting*, vol. 26, no. 1, pp. 44–60, 2011. doi:10.1175/2010WAF2222386.1. https://scholars.lib.ntu.edu.tw/handle/123456789/463591

[9] 中央社，〈颱風影響　南橫公路梅山口到向陽段預警性封路〉，2025-07-19。https://www.cna.com.tw/news/aloc/202507190089.aspx

[10] 中央社，〈樺加沙影響　南橫台東端初來至向陽持續封閉〉，2025-09-23。https://www.cna.com.tw/news/ahel/202509230076.aspx

[11] 中央氣象署，〈氣象資料開放平臺 Opendata API 說明文件〉，2026-10-31 開啟。https://opendata.cwa.gov.tw/apidoc/v1

[12] 交通部，〈省道發布路段即時路況資料〉，政府資料開放平臺，2026-10-31 開啟。https://data.gov.tw/dataset/161171

[13] Google 台灣官方部落格，〈Google 地圖機車模式正式在台上線〉，2018-07-18。https://taiwan.googleblog.com/2018/07/google.html

[14] REVER, “REVER PRO,” 產品頁，2026-10-31 開啟。https://www.rever.co/pro

[15] B. Deng, Y. Feng, Z. Liu, Q. Wei, X. Zhu, S. Chen, Y. Guo, Y. Wang, “RETAIL: Towards Real-world Travel Planning for Large Language Models,” *Proceedings of EMNLP 2025*, pp. 14870–14902, 2025. https://aclanthology.org/2025.emnlp-main.752/

[16] M. L. Dihan, M. T. Hassan, M. T. Parvez, M. H. Hasan, M. A. Alam, M. A. Cheema, M. E. Ali, M. R. Parvez, “MapEval: A Map-Based Evaluation of Geo-Spatial Reasoning in Foundation Models,” *Proceedings of the 42nd International Conference on Machine Learning (ICML 2025)*, 2025. https://arxiv.org/abs/2501.00316

[17] A. Gundawar, M. Verma, L. Guan, K. Valmeekam, S. Bhambri, S. Kambhampati, “Robust Planning with LLM-Modulo Framework: Case Study in Travel Planning,” arXiv:2405.20625 (workshop paper), 2024. https://arxiv.org/abs/2405.20625

[18] Y. Hao, Y. Chen, Y. Zhang, C. Fan, “Large Language Models Can Solve Real-World Planning Rigorously with Formal Verification Tools,” *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the ACL (NAACL 2025), Volume 1: Long Papers*, pp. 3434–3483, 2025. https://aclanthology.org/2025.naacl-long.176

[19] Google Maps Platform，“Countries and regions supported for two-wheeled vehicles”（Routes API），頁面更新 2026-10-30。
https://developers.google.com/maps/documentation/routes/coverage-two-wheeled

[20] D. Wang, J. Zhang, W. Cao, J. Li, Y. Zheng, “When Will You Arrive? Estimating Travel Time Based on Deep Neural Networks,” *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI-18)*, vol. 32, no. 1, pp. 2500–2507, 2018. https://ojs.aaai.org/index.php/AAAI/article/view/11877

[21] C. Xu, Q. Wang, L. Sun, “Link Representation Learning for Probabilistic Travel Time Estimation,” *IEEE Transactions on Intelligent Transportation Systems*, 2025 (arXiv:2407.05895, 2024). https://arxiv.org/abs/2407.05895

[22] H. Ni, F. Liu, X. Ma, L. Su, S. Wang, D. Yin, H. Xiong, H. Liu, “TP-RAG: Benchmarking Retrieval-Augmented Large Language Model Agents for Spatiotemporal-Aware Travel Planning,” *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP 2025)*, pp. 12392–12418, 2025. https://aclanthology.org/2025.emnlp-main.626

[23] P. Lemonakis, G. Botzoris, A. Galanis, N. Eliou, “Speed Models for Motorcycle Riders for Two-lane Rural Roads,” *WSEAS Transactions on Environment and Development*, vol. 17, pp. 595–603, 2021. doi:10.37394/232015.2021.17.57. https://wseas.com/journals/articles.php?id=165

[24] S. R. Geedipally, M. P. Pratt, B. Dadashova, L. Wu, M. Shirazi, “Evaluating Curve Speed Behavior Using SHRP 2 Data,” Texas A&M Transportation Institute / ATLAS Center, Report ATLAS-2017-21, 2017. https://rosap.ntl.bts.gov/view/dot/36257

[25] A. Wood, W. Mackaness, T. I. Simpson, J. D. Armstrong, “Improved prediction of hiking speeds using a data driven approach,” *PLOS ONE*, 2023. doi:10.1371/journal.pone.0295848. https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0295848

[26] C. Xin, Z. Wang, C. Lee, P.-S. Lin, T. Chen, R. Guo, Q. Lu, “Development of crash modification factors of horizontal curve design features for single-motorcycle crashes on rural two-lane highways: A matched case-control study,” *Accident Analysis & Prevention*, vol. 123, pp. 51–59, 2019. https://www.cutr.usf.edu/2019/02/development-of-crash-modification-

factors-of-horizontal-curve-design-features-for-single-motorcycle-crashes-on-rural-two-lane-highways-a-matched-case-control-study/

[27] S.-R. Yang, C.-W. Shen, C.-M. Huang, C.-T. Lee, C.-T. Cheng, C.-Y. Chen, “Prediction of Mountain Road Closure Due to Rainfall-Induced Landslides,” *Journal of Performance of Constructed Facilities*, vol. 26, no. 2, pp. 197–202, 2012. doi:10.1061/(ASCE)CF.1943-5509.0000242. https://ir.lib.ncu.edu.tw/ir/handle/987654321/103259

[28] calimoto, product website. https://calimoto.com/en （2026-10-31 査閲）

[29] Kurviger, product website. https://kurviger.com/en （2026-10-31 査閲）

[30] REVER, product website. https://www.rever.co/ （2026-10-31 査閲）

[31] BMW Motorrad Connected, Apple App Store listing. https://apps.apple.com/app/id1250173746 （2026-10-31 査閲）

[32] B. Liu, J. Ge, J. Wang, “Vaiage: A Multi-Agent Solution to Personalized Travel Planning,” arXiv:2505.10922, 2025. https://arxiv.org/abs/2505.10922

[33] Z. Ye, X. Lin, “ROAM: Retrieval-Augmented Optimization for Feasible Multi-Day Itinerary Planning,” arXiv:2611.09407, 2026. https://arxiv.org/abs/2611.09407

[34] Texas Department of Transportation. *Roadway Design Manual*, Section 20.4.2 Horizontal Curves (Specific). TxDOT, online edition（未載明年份）. https://www.txdot.gov/manuals/des/rdw/chapter-20-motorcyclist-design-considerations/20-4-highway-features/20-4-2-horizontal-curves--specific--.html

[35] Department for Transport. *The Highway Code*: General rules, techniques and advice for all drivers and riders (103 to 158). GOV.UK, online edition. https://www.gov.uk/guidance/the-highway-code/general-rules-techniques-and-advice-for-all-drivers-and-riders-103-to-158

[36] Williams, V., McLaughlin, S., Atwood, J., Buche, T. “Factors that Increase and Decrease Motorcyclist Crash Risk.” Virginia Tech Transportation Institute / Motorcycle Safety Foundation (MSF 100 Motorcyclists Naturalistic Study), 2016. https://msf-usa.org/wp-content/uploads/2021/07/Risk_Factors_From_MSF_100_Study_Paper-1.pdf

[37] Inside State Government. “Victoria Police revs up group safety message for motorcyclists”（轉載 Victoria Police 新聞稿）, 2025-10-14. https://www.insidestategovernment.com.au/victoria-police-revs-up-group-safety-message-for-motorcyclists/

[38] 中央氣象署。《日出日沒時刻：全臺各縣市年度逐日日出日沒時刻資料》產品說明文件，2023。https://www.cwa.gov.tw/Data/data_catalog/8-1-1.pdf

[39] NSW Government. “Fatigue”（Safe riding behaviour for motorcyclists）. nsw.gov.au, n.d. https://www.nsw.gov.au/driving-boating-and-transport/roads-safety-and-rules/motorcycles-and-scooters/safe-riding-behaviour-for-motorcyclists/fatigue

[40] Visordown. “Government runs study into rider fatigue.” Visordown, 2019. https://www.visordown.com/news/general/government-runs-study-rider-fatigue

[41] 台灣中油股份有限公司。〈台灣中油公司加油站服務資訊〉，政府資料開放平臺。https://data.gov.tw/dataset/6065

[42] 聯合報（張議晨）。〈高雄山區豪雨狂炸…全台 3 日累積雨量包辦前 2 名 台 20 線部分路段今恢復通行〉，2026-06-10。https://udn.com/news/story/7266/9557495

[43] Shinn, N., et al. “Reflexion: Language Agents with Verbal Reinforcement Learning.” arXiv, 2023. https://arxiv.org/abs/2303.11366

[44] Valmeekam, K., Marquez, M., & Kambhampati, S. “Can Large Language Models Really Improve by Self-critiquing Their Own Plans?” arXiv, 2023. https://arxiv.org/abs/2310.08118

[45] IIHS. “Largest study of its kind strengthens argument for motorcycle ABS.” IIHS News, 2021. https://www.iihs.org/news/detail/largest-study-of-its-kind-strengthens-argument-for-motorcycle-abs

[46] IIHS. “Motorcycle ABS benefits both high-risk and low-risk riders.” IIHS News, 2014. https://www.iihs.org/news/detail/motorcycle-abs-benefits-both-high-risk-and-low-risk-riders

[47] Highway Loss Data Institute. “Evaluation of motorcycle antilock braking systems, alone and in conjunction with combined control braking systems: an update.” HLDI Bulletin 42(13), 2025. https://www.iihs.org/media/66a450d6-b3c2-40cd-9716-cab3a7c37ff9/W7ERBQ/HLDI%20Research/Bulletins/hldi_bulletin_42.13.pdf

[48] Purvis, B. “Why isn’t ABS saving our lives?” Bennetts BikeSocial, 2019. https://www.bennetts.co.uk/bikesocial/news-and-views/features/bikes/why-isnt-abs-saving-our-lives

附錄 A：AI 使用說明

依作業規範「AI is OK」：本提案在研究、撰寫與製作過程中使用 AI 工具。下表說明每項工作中 AI 做了什麼，以及哪些由組員決定、如何驗證。主要指令與提示詞紀錄放在 GitHub：`final_project/doc/proposal/ai-usage-log.md`。

工作	使用的工具	AI 做了什麼	組員決定與驗證方式
選題與範圍	Claude Code（Claude Opus 5.5）	盤點候選題目並比較；以公開資料集 VED 做流程可行性檢查；檢查一趟實際 GPX 的資料格式	題目與 ①–⑩ 各項範圍由組員逐項決定，紀錄在 `doc/brief/architecture-scope.md`
證據與文獻	Claude Code（含網頁搜尋與子代理）	搜尋官方統計、論文與新聞；起草 Introduction、Related Work、Deep Research	每個數字與引用都對照原始頁面，查證紀錄保存在各章 Markdown 原稿；無法查證者刪除或標註
系統設計	Claude Code	起草架構圖、多 Agent 分工、數學模型、流程圖、Pseudocode、評估計畫	設計取捨（整趟 P90 校正、驗證規則、承諾範圍）由組員審閱
文件與簡報製作	Claude Code 撰寫的產生程式；pandoc、python-pptx、mermaid-cli	把 Markdown 原稿轉成 Word、PDF、PPT 與圖	產生程式放在 `final_project/tools/`，可重現
簡報影片	Microsoft Edge 線上朗讀（zh-TW-HsiaoChenNeural）、ffmpeg	依逐字稿產生 AI 旁白、字幕與影片	逐字稿由組員審閱

AI 產出的內容都經過人工審閱。本提案不含任何實驗結果，預期成果均標示為待驗證。